

Tối ưu hóa Logistics dựa trên Big Data thời tiết và vận tải tại TP.HCM cho Startup Xe Dù (UDS)

Dữ liệu lớn


Tiêu đề & Bối cảnh

Lí do chọn đề tài

- TP.HCM hiện có **159 điểm ngập**, trong đó **57 điểm ngập nặng**, ảnh hưởng trực tiếp đến vận chuyển đô thị.
- **23% chậm trễ logistics** liên quan đến thời tiết; thiệt hại vận tải ước tính **8–9 tỷ USD/năm**.
- Khu vực đô thị mất khoảng **32 triệu giờ** vận chuyển, tương đương **3,4 tỷ USD** do thời tiết; 1 ngày đóng đường có thể gây thiệt hại **76 triệu USD**.
- Doanh nghiệp ứng dụng AI + Big Data đã ghi nhận giảm tiêu thụ nhiên liệu **12–28%** và tăng tỷ lệ giao đúng hạn **15–35%**.
- Một số đơn vị giao hàng như Ninja Van và Flex Speed rút khỏi thị trường → cạnh tranh logistics ngày càng khốc liệt.

Nguồn: FHWA – Road Weather Management; OpenWeather (2025); GEODIS; Visual Crossing (2026); Tuổi Trẻ (2026); VnExpress (2026); CafeF (2025); Kênh14 (2026).





01 Tỷ lệ hủy đơn & giao hàng trễ

Làm thế nào để xác định và dự báo được nguy cơ giao hàng trễ ($\text{delay_min} > 0$) đối với các dịch vụ giao hàng nhanh 3h và 5h của UDS trong các điều kiện mưa lớn (lượng mưa $> 5\text{mm}$) tại khu vực có nguy cơ ngập lụt tại TP.HCM giai đoạn 2023-2024?

02 Thu nhập tài xế

Mối quan hệ giữa lượng mưa, mức độ ngập lụt và tình trạng ùn tắc giao thông ảnh hưởng như thế nào đến thu nhập của tài xế?


03 Tuyến đường vận chuyển

Mối quan hệ giữa các điểm ngập lụt và hiệu quả lộ trình, quãng đường và thời gian vận chuyển thực tế tại TP.HCM vào mùa mưa 2023-2024 là gì?



Prepare

Data Pipeline



Dữ liệu đầu vào & nguồn dữ liệu

Dữ liệu

uds_orders.csv

Dữ liệu thời tiết

Dữ liệu ngập lụt

Dữ liệu giao thông

Dữ liệu thị trường

Nguồn

Hệ thống nội bộ UDS (Kaggle)

OpenWeatherMap / Visual Crossing

UDI Maps / Cổng dữ liệu mở TP.HCM

Cổng GTVT TP.HCM

Tổng hợp thị trường logistics



Process

Apache Spark (PySpark) + HDFS

Cleaning

- ✓ Null values
- ✓ Duplicates
- ✓ Schema
- ✓ Timezone UTC+7
- ✓ Unit standardize



Join/Merge

orders
weather
flood
traffic
market



Output

final_features
(.parquet)



Join key: hour_timestamp
(đồng bộ dữ liệu theo giờ)



ANALYZE

May 18, 2026

1 Q1 – ETA Prediction

- **Mục tiêu:** Đánh giá khả năng dự báo và điều chỉnh động thời gian giao hàng (**Dynamic ETA**) bằng cách tích hợp dữ liệu thời tiết, giao thông và ngập lụt cục bộ.

1.1 Khám phá dữ liệu (EDA)

```
[17]: import pandas as pd

df = pd.read_csv("/Users/doanquochuy/bigdata-ueh/src/data/analysis/q1/
↳compound_risk/compound_risk.csv")

df[['risk_segment', 'late_probability_pct']].sort_values(
    by='late_probability_pct', ascending=False
)
```

```
[17]:
```

	risk_segment	late_probability_pct
0	STRESS_Flood_Only	24.23
1	NORMAL	18.34
2	HIGH_Rain_Only	4.88
3	CRITICAL_Rain_Flood	0.00

```
[18]: import pandas as pd


df = pd.read_csv("/Users/doanquochuy/bigdata-ueh/src/data/analysis/q1/
↳rain_impact/rain_impact.csv")

df[['rain_level', 'late_rate_percentage']].sort_values(
    by='late_rate_percentage', ascending=False
)
```

```
[18]:
```

	rain_level	late_rate_percentage
2	light	26.68
1	no_rain	20.70
3	moderate	16.98
7	light	13.29
6	no_rain	11.13

0	heavy	5.00
4	heavy	0.00
5	moderate	0.00



Từ các kết quả trên, EDA rút ra các kết luận chính:

1. Trễ giao hàng **không tỷ lệ thuận với lượng mưa**.
2. **Ngập lụt cục bộ** là yếu tố rủi ro quan trọng nhất.
3. ETA hiện tại:
 - Quá dư (over-buffer) trong mưa lớn
 - Thiếu thích ứng trong các tình huống ngập nhẹ, phân tán
4. Nhiều phân đoạn mưa/ngập là **rare events**, không đủ dữ liệu để huấn luyện mô hình thuần ML.

1.2 Mô hình dự đoán ETA

Các insight từ EDA dẫn trực tiếp đến các quyết định mô hình hóa sau:

- **Data Segmentation:** Tách theo bối cảnh vận hành để tránh trộn các phân phối khác nhau.
- **Feature Engineering:** Ưu tiên đặc trưng định lượng phản ánh ngập (**severity_score**) hơn là nhãn mưa.
- **Model Gating:** Không huấn luyện mô hình cho các phân đoạn thiếu dữ liệu để đảm bảo tính ổn định thống kê.
- **Dynamic ETA:** Thay vì tối ưu giao nhanh hơn, mục tiêu là **dự báo ETA sát thực tế hơn theo bối cảnh**.

```
[ ]: # Context-aware feature (core idea)
df = df.withColumn(
    "context_segment",
    when(col("has_flood")==1, "flood_only")
    .when(col("is_heavy_rain")==1, "rain_only")
    .otherwise("normal")
)
```

```
# FEATURE VECTOR (CONTEXT-AWARE)
FEATURE_COLS = [
    # Distance & load
    "shipping_km",
    "weight",

    # Traffic & market
    "traffic_penalty",
    "avg_vehicle_speed_kmh",
    "active_delivery_vehicles",

    # Flood (primary)
    "has_flood",
    "flood_severity",
    "flood_peak_interaction",

    # Temporal
    "is_peak_hour",
]
```

1.2.1 Tổng hợp RMSE qua các giai đoạn

Giai đoạn huấn luyện	Đặc điểm kỹ thuật nổi bật	Kết quả RMSE (Phút)	Ý nghĩa & Đánh giá
1. Baseline (Cơ bản)	Train trên toàn bộ Dataset, sử dụng các FEATURES đơn giản.	- Linear Regression: 479.77- Random Forest: 482.95	Sai số ~8 tiếng. Mô hình bị kéo lệch nặng nề bởi các điểm dị biệt (Outliers) như đơn trễ 7 ngày và sự trộn lẫn các loại dịch vụ (Lưu kho vs Hỏa tốc).
2. Feature Engineering & Filtering	Thêm features (weather, flood, market). Giới hạn serviceType (3h, 5h). Loại bỏ đơn trễ > 24h.	- Dịch vụ 3h: 206.26- Dịch vụ 5h: 291.15	Cải thiện ~7-12% so với baseline. Việc tách riêng dịch vụ giúp mô hình bắt đầu học được quy luật của nhóm hỏa tốc, nhưng sai số vẫn lớn hơn khung thời gian cam kết.

Giai đoạn huấn luyện	Đặc điểm kỹ thuật nổi bật	Kết quả RMSE (Phút)	Ý nghĩa & Đánh giá
3. Advanced Segmentation (Phân đoạn nâng cao)	Data Segmentation (theo bối cảnh bình thường/mưa/ngập). Huấn luyện trên SLA-compliant subset .	- Dịch vụ 3h (Normal): 39.86 - <i>Các phân đoạn khác:</i> Bị skip do thiếu dữ liệu.	Bước đột phá kỹ thuật. Sai số giảm xuống dưới 40 phút, mức độ tin cậy đạt ~78-80% cho điều kiện bình thường, đủ điều kiện triển khai bản Beta.
4. Context-aware Regression (Revised)	Ưu tiên flood severity, traffic phi tuyến, bỏ rain khỏi vector.	37.73 (3h_normal). 76.16 (5h_normal)	Cải thiện thêm RMSE , mô hình hội tụ ổn định, phù hợp triển khai Dynamic ETA.

2 Q2 – Economic Impact

- **Mục tiêu:** Định lượng chính xác mức độ sụt giảm thu nhập tài xế từ dữ liệu quan sát thực tế


```
[ ]: # Core metric: income efficiency
income_per_min = income / actual_duration_min
```

```
[19]: import pandas as pd

df = pd.read_csv("/Users/doanquochuy/bigdata-ueh/src/data/analysis/q2/penalty/
↳penalty.csv")

df[['context_segment', 'income_per_min_raw']].sort_values(
    by='income_per_min_raw', ascending=True
)
```

```
[19]: context_segment  income_per_min_raw
3      flood_only      187.41
2      rain_only       228.93
1      rain_flood       256.91
0      normal          266.53
```



2.0.1 Insight chính

1. Flood-only là bối cảnh gây thiệt hại kinh tế lớn nhất
2. Rain-only có tác động trung bình, không phải yếu tố chính
3. Rain + Flood không phải tình huống tệ nhất
 - Dù thời gian giao hàng cao nhất (398.65 phút)
 - Thu nhập/min vẫn gần với normal (256.91)
4. Ngập lụt là hiện tượng độc lập với mưa

Việc tồn tại một lượng lớn đơn hàng thuộc nhóm flood_only cho thấy:

Ngập lụt trong dữ liệu không phụ thuộc trực tiếp vào lượng mưa tại thời điểm giao hàng, mà phản ánh trạng thái tích tụ của hạ tầng đô thị.

3 Q3: Route Efficiency

- **Mục tiêu:** Định lượng mối quan hệ giữa các điểm ngập lụt, quãng đường danh nghĩa và hiệu quả vận chuyển thực tế tại TP.HCM.

```

[ ]: # =====
# CORE SUMMARY (DISTANCE - TIME - EFFICIENCY)
# =====
logger.info("Running core Q3 analysis...")

core_summary = spark.sql("""
    SELECT
        context_segment,
        COUNT(*) AS volume,

        ROUND(AVG(shippingDistance), 2) AS avg_distance_km,

        ROUND(AVG(actual_duration_min), 2) AS avg_duration_min,


```

```

ROUND(AVG(shippingDistance / actual_duration_min), 4) AS avg_efficiency,

ROUND(AVG(traffic_congestion_index), 2) AS avg_traffic
FROM uds_spatial_data
WHERE actual_duration_min > 0
GROUP BY context_segment
ORDER BY avg_efficiency DESC
))))))

```



Phân tích cho thấy ngập lụt không làm thay đổi đáng kể quãng đường danh nghĩa nhưng làm tăng thời gian vận chuyển và giảm hiệu quả lộ trình thông qua các gián đoạn không gian. Trong khi thời tiết mưa gây slowdown mang tính toàn cục, ngập lụt tạo ra sự không hiệu quả mang tính cục bộ và phi tuyến. Điều này khẳng định rằng vấn đề vận hành trong môi trường đô thị không nằm ở độ dài lộ trình, mà ở sự suy giảm khả năng di chuyển thực tế do yếu tố không gian.

Act

Insight → Prototype

A1 - Dashboard ETA

- ML dự báo ETA
- Cảnh báo rủi ro
- ETA thời gian thực

A2 - Dynamic Pricing

- Thưởng tài xế
- Ưu đãi KH
- Giảm hủy đơn

A3 - SMART ROUTING

- Tránh điểm ngập
- Safe Path
- Tối ưu thời gian



Mục tiêu

Weather-Adaptive Logistics cho UDS



Limitatons

Giải quyết đồng thời 3 bài toán

Hạn chế dữ liệu để train model

Future Work

Real-time pipeline
(Kafka + Spark Streaming)

Graph-based routing
(GraphX – Safe Path)

Design Thinking validation
(user testing)

Towards MVP System



Tài liệu tham khảo

CafeF. (2025, September 4). *Ninja Van Việt Nam thông báo dừng toàn bộ dịch vụ giao nhận nhanh từ cuối tháng 9/2025

FHWA. (2016). Regional assessment of weather impacts on freight – Chapter 1. U.S. Department of Transportation.

FHWA. (n.d.). Road weather management overview. U.S. Department of Transportation.

Flexlogistik. (2026, March 23). Logistics firms invest in advanced route optimization.

Kenh14. (n.d.). Một đơn vị giao hàng online dừng dịch vụ từ 31/3.

OpenWeather. (2025, April 29). Weather intelligence for last-mile delivery. OpenWeather Blog.

Tuổi Trẻ. (2026, April 10). TP.HCM lên lộ trình xử lý 159 điểm ngập trong 5 năm tới. Tuổi Trẻ Online.

Visual Crossing. (n.d.). Loading weather into your datastores.

VnExpress. (2026, May 2). Nhiều đường ở TP HCM ngập sâu sau mưa lớn đầu mùa. VnExpress.

Thank you

